

Projet de Machine Learning

Classification du risque cardiaque et régression du LDL-cholestérol

Christopher Brûlé Corentin Brandam Romain Deleris Augustin Traissac

INSA Toulouse – 4A MA

6 juin 2026

Plan de la présentation

- 1 Introduction générale
- 2 Analyse exploratoire des données
- 3 Classification : prédiction du risque cardiaque
- 4 Régression : prédiction du LDL-cholestérol

1 Introduction générale

Objectif du projet

Contexte

Dataset médical synthétique de **15 000 patients** décrit par **19 variables cliniques et comportementales**.

Tâches étudiées

- **Classification**
prédiction du risque cardiaque
- **Régression**
estimation du taux de LDL

Familles de modèles

- modèles linéaires ;
- SVM et kNN ;
- arbres et ensembles ;
- réseaux de neurones.

Démarche

EDA → Prétraitement → Modélisation → Évaluation

Chargement et vérification des données


Points vérifiés

- cohérence des types ;
- détection des valeurs manquantes ;
- recherche de doublons ;
- contrôle des valeurs aberrantes.

Résultat

Le dataset est globalement propre et directement exploitable après un prétraitement léger.

Visualisation




Analyse exploratoire des données

Analyse univariée – Variables quantitatives


Constats

- Distributions gaussiennes.
- Pas de transformation nécessaire.



Analyse univariée : Variables qualitatives

Répartition des variables qualitatives




Constats

- Genre quasi équilibré.
- Fumeurs : environ 30%.
- Antécédents familiaux minoritaires.
- Cible assez équilibrée : 56.4%/43.6%.

Conclusion

La classification ne nécessite pas de rééquilibrage fort des classes.

Analyse bivariable : Corrélations quantitatives




Corrélations fortes

- Cholestérol total / LDL : 0.83.
- Pression systolique / diastolique : 0.81.
- Poids / IMC : 0.80.

Enjeu

Ces redondances peuvent introduire de la multicollinéarité dans les modèles linéaires.

Analyse bivariable : Variables quantitatives et risque



Variables discriminantes


- Âge plus élevé chez les patients à risque.

Lecture

Les écarts existent, mais les distributions se recouvrent largement.

Analyse bivariable : Variables qualitatives et risque

Proportion de risque cardiaque selon les variables qualitatives



Facteurs marquants

- Tabagisme : risque élevé nettement plus fréquent.
- Antécédents familiaux : fort signal discriminant.
- Activité physique : effet protecteur modéré.

Interprétation

- Seuil des **80%** atteint avec environ **6 composantes**.
- Plan **PC1–PC2** : **41,3%** de variance expliquée.
- Structure fortement corrélée des variables cardio-métaboliques.

Principaux constats

- Variables médicales globalement cohérentes.
- Corrélations fortes : Cholestérol total/LDL, PAS/PAD, Poids/IMC.
- Facteurs associés au risque : âge, pression artérielle, cholestérol, glycémie.
- Variables qualitatives discriminantes : tabagisme, antécédents familiaux, activité physique.

Implications pour la modélisation

- Standardisation nécessaire.
- Vigilance sur la multicolinéarité.
- Prédiction multifactorielle.

- Séparation des variables explicatives et des variables cibles.
- Encodage des variables qualitatives.
- Standardisation des variables numériques.
- Séparation train/test.
- Validation croisée pour le réglage des hyperparamètres.

Message clé

On garde le test set uniquement pour l'évaluation finale, afin d'éviter une comparaison biaisée.

Classification

prédiction du risque cardiaque

Problème de classification

- Variable cible : Heart_Disease_Risk.
- Problème binaire : risque faible / risque élevé.
- Métriques utilisées :
 - accuracy ;
 - recall ;
 - AUC-ROC.

Message clé

Dans un contexte médical, le recall peut être particulièrement important pour limiter les faux négatifs.

- Premier modèle de référence.
- Modèle simple et interprétable.
- Comparaison :
 - avec/sans sélection de variables ;
 - avec/sans pénalisation

Accuracy : 73.2% - AUC : 0.807

		Prédit	
		Positif	Négatif
Réal	Positif	1362	496
	Négatif	308	834

Table – Matrice de confusion pour le modèle sans pénalisation ni sélection

Régression logistique : avec pénalisation




Figure – Lasso




Figure – Ridge





Figure – Elastic net

Performances similaires et modèles interprétables

Régression logistique : avec sélection de variables et comparaison

- RFECV : retire récursivement les variables peu influentes (critère AUC)
- Variables supprimées :
Gender_1, Alcohol_consumption_1, Height_cm, Weight_cm, Alcohol_Consumption_2, Diastolic_BP, Cholesterol_total, Cholesterol_HDL.
- Performance équivalente $\Rightarrow$ meilleur modèle



kNN : Choix du nombre de voisins

Paramètres testés

- k : nombre de voisins ;
- distance : euclidienne / Manhattan ;
- pondération : uniforme / distance.

Modèle retenu

- $k = 275$;
- distance de Manhattan ;
- pondération par distance.

SVM : Sélection du noyau

Principe

- Recherche d'une frontière de séparation optimale.
- Comparaison entre noyau linéaire et noyau RBF.
- Validation croisée sur les hyperparamètres.

Modèle retenu

- noyau linéaire ;
- $C = 1$;
- balanced accuracy CV : 0.719.


Pourquoi pas RBF ?

- Score CV légèrement inférieur.
- Écart train / validation plus marqué.
- Flexibilité accrue, mais pas de meilleur gain test.

Lecture

Le noyau linéaire offre le meilleur compromis entre simplicité, stabilité et performance.

kNN vs SVM : Comparaison finale



Résultats


- Le SVM obtient les meilleurs scores globaux.
- L'écart est particulièrement visible sur :
 - la balanced accuracy ;
 - le F1-score.
- Les deux modèles atteignent une AUC proche de 0.80.

Conclusion



Le SVM linéaire fournit le meilleur compromis entre performance et généralisation.

Arbre CART complet

Arbre CART retenu après sélection de la profondeur



Influence des paramètres




Observation

Quand max_depth augmente $\Rightarrow$ overfitting.


Quand min_samples_leaf diminue $\Rightarrow$ overfitting.

Optimisation : Pruning et Bagging

Pruning (Élagage)





Bagging (Bootstrap Aggregating)



Observation

Le **Pruning** réduit le surapprentissage en simplifiant l'arbre,
le **Bagging** réduit la variance en combinant plusieurs modèles indépendants.

Influence du nombre d'arbres et importance des variables




Observation

L'erreur diminue avec le nombre d'arbres conservés.

Le graphique de droite illustre les variables les plus importantes dans le Random Forest.

Différents Arbres de Boosting


Gradient Boosting : courbes de validation par fold et par configuration



Observation

On converge plus vite avec un learning rate et un max_depth élevés.
Les résultats restent cependant très similaires.

Comparaison de toutes les méthodes



Résultat

Le Gradient Boosting est le modèle avec la meilleur Accuracy.
De manière assez logique, le CART donne le moins bon résultat.

Perceptron multicouche

Paramètres retenus pour l'architecture :

- nombre de couches cachées : **1**
- taille de la couche : **5**
- fonction d'activation : **$\tanh$**
- pénalisation : $\alpha = \mathbf{0.001}$

	Prédit	
	Positif	Négatif
Réel Positif	1342	490
Réel Négatif	328	840

Table – Matrice de confusion

Accuracy : **0.7396** – AUC : **0.803**

Conclusion : Modèles de classification

Variables clés

Tabagisme, antécédents familiaux, activité physique, âge, pression artérielle, LDL et glycémie.

Résultats principaux

- AUC très proches : **0.76 – 0.81**
- Meilleurs modèles : **RFECV puis LASSO, Ridge et ElasticNet**

Conclusion

- Risque cardiaque : **multifactoriel**
- Modèle retenu : **régression logistique**
- Bon compromis :
 - performance
 - interprétabilité

Régression

prédiction du LDL-cholestérol

Problème de régression

- Variable cible : Cholesterol_LDL.
- Objectif : prédire une valeur quantitative continue.
- Métriques utilisées :
 - RMSE ;
 - MAE ;
 - R^2 .

Message clé

On reprend la même logique que pour la classification, mais avec des métriques adaptées aux variables continues.

Objectif

Construire des modèles de référence simples pour prédire Cholesterol_LDL.

Modèles testés

- Régression linéaire complète.
- Sélection backward AIC.
- Sélection backward BIC.
- Ridge et Lasso.

Résultat central

- RMSE test $\approx$ **9.79**.
- R^2 test $\approx$ **0.69**.
- Performances quasi identiques.
- Peu de gain à complexifier.

Variables retenues

- AIC :
 - Cholesterol_Total
 - Age
 - Systolic_BP
 - Family_History
- BIC :
 - modèle encore plus parcimonieux.

Ridge / Lasso

- Ridge : coefficients rétrécis.
- Lasso : **4 coefficients non nuls.**
- Même performance prédictive.
- Meilleure lisibilité du modèle.

Conclusion




La prédiction de Cholesterol_LDL est principalement linéaire et dominée par Cholesterol_Total.
La sélection améliore surtout l'interprétabilité, pas la performance.

KNN régression

- Prédiction par moyenne locale.
- Distance euclidienne, moyenne pondérée, $k = 20$.

SVR


- Version régression du SVM.
- Noyaux linéaire.
- Hyperparamètres : $C = 0.5$, $\epsilon = 2$.



CART de régression

- profondeur maximale : 5
- nombre minimal d'observations par feuille : 20

Premiers niveaux de l'arbre CART de régression



Bagging

- Bootstrap + moyenne des arbres, réduction de la variance.
- 200 arbres, minimum 20 individus par feuille

$$RMSE = 9.908$$

$$R^2 = 0.687$$

Random Forest

- Bagging + sélection aléatoire de variables.
- 200 arbres, profondeur de 8, pas de sélection de variables !

$$RMSE = 9.874$$

$$R^2 = 0.689$$

Boosting


- Correction progressive des erreurs.
- Gradient boosting, 300 arbres de profondeur 1, learning rate de 0.05

$$RMSE = 9.822$$

$$R^2 = 0.692$$

⇒ Performances similaires, Cholesterol_total concentre 99% de l'information prédictive.

Réseaux de Neurons pour la régression




Résultat

Le réseaux de neurones donne de bon résultats.

Cependant, la dispersion est plus importante qu'avec d'autres méthodes.

Régression – Comparaison des modèles



Meilleurs modèles

- Lasso : RMSE = **9.782**
- Linéaire complète : 9.788
- Ridge : 9.788
- Linéaire sélectionnée : 9.790

Lecture

- Écarts de performance très faibles.
- Les modèles linéaires restent compétitifs.
- Peu de gain avec les modèles complexes.

Résultat principal

Les modèles linéaires obtiennent les meilleures performances, avec des écarts très faibles entre les différentes approches.

Meilleur modèle

Lasso
RMSE test :
9.78

Lecture

- Peu de gain avec les modèles complexes.
- Signal dominé par :
Cholesterol_Total

Performance globale

- $RMSE \approx 9.8$
- $MAE \approx 7.7$
- $R^2 \approx 0.69$

Deux structures très différentes

Classification – Risque cardiaque

Accuracy ≈ 0.73

- RFECV et lasso
- Variables majeures :
 - tabagisme
 - pression artérielle
 - antécédents

Régression – LDL

$R^2 \approx 0.69$ $RMSE \approx 9.8$

- Domination du linéaire.
- Lasso / Ridge les plus stables.
- Variable centrale :
 - Cholesterol_Total

Conclusion

Risque cardiaque $\rightarrow$ *combinaison de plusieurs facteurs*

LDL $\rightarrow$ *structure linéaire simple*

Conclusion : Enseignements méthodologiques

Enseignements clés

- **Parcimonie** : complexité $\neq$ meilleure performance.
- **Interprétabilité** : Lasso et arbres élagués plus exploitables en contexte médical.
- **Robustesse** : validation croisée + test final indispensables.
- **EDA essentielle** : la structure des données guide déjà le choix du modèle.

Leçon retenue

Une relation linéaire bien identifiée dès l'analyse exploratoire limite souvent l'intérêt des modèles de régression.

Précision • Simplicité • Explicabilité

Conclusion : Perspectives possibles

- **Changement des variables** : éliminer la variable Cholesterol Total pour la réalisation de la régression linéaire.
- **Modèles de Deep Learning** : implémenter des modèles de réseaux de neurones plus complexes pour la classification.
- **Données temporelles** : intégrer l'évolution des constantes du patient sur plusieurs années pour une prédiction dynamique.
- **Déploiement** : concevoir une interface d'aide au diagnostic pour tester le modèle en conditions réelles.

Merci pour votre attention

Projet de Machine Learning

Classification du risque cardiaque et régression du LDL-cholestérol

Christopher Brûlé Corentin Brandam Romain Deleris Augustin Traissac

INSA Toulouse – 4A MA

26 mai 2026